


Monte Carlo Yöntemleri ve Ising Modeli



Arif Bayırlı

Boğaziçi Üniv. Fizik Bölümü

Ising Modeli



- 2 boyutlu spin dizisi – **durum uzayı** $\{-1$ (aşağı), 1 (yukarı) $\}$
- Toplam Enerji:

$$E = - \left(\sum_{\langle i,j \rangle} J \sigma_i \sigma_j + \sum_j B \sigma_j \right)$$

- $\langle i, j \rangle$: komşuluk ilişkisi
- $J = \pm 1$ Ferromanyetik/Anti-ferromanyetik
- B : Manyetik alan
- Sadece **spin etkileşimlerini** göz önüne alacağız ($B = 0$)
- Her bir durumun olasılığı:

$$\pi(\sigma) = \frac{e^{-\beta E(\sigma)}}{Z}$$

- Z : Bölüşüm fonksiyonu (Partition Function)
- İlgilendiğimiz problemler:
 - Ortalama mıknatıslanma: $\frac{1}{N} \sum_j \sigma_j$
 - Ortalama enerji: \bar{E}
- Z 'i hesaplamak için durum uzayındaki her bir noktayı gezmeliyiz
 - Bizim örneğimizde $N = 9 \gg 2^9 = 512$ olasılık
 - Büyük N için, örneğin $N = 1000$ için 2^{1000} (astronomik astronomik)

Oyuncak Model: Yazı gelene kadar at!



Problem:

$P(n)$: Elimdeki parayı artarda attığımda üzerinde yazı yüzünün ilk defa $(n+1)$ denemede gelme olasılığı $(n= 0, 1, 2, 3, \dots)$

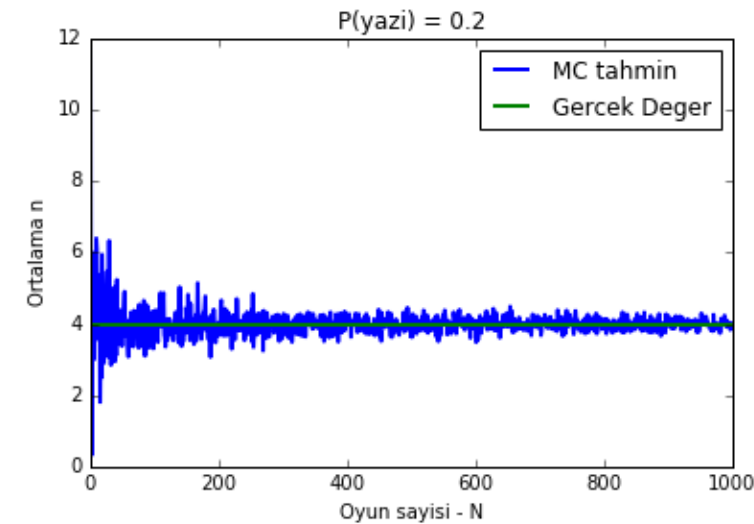
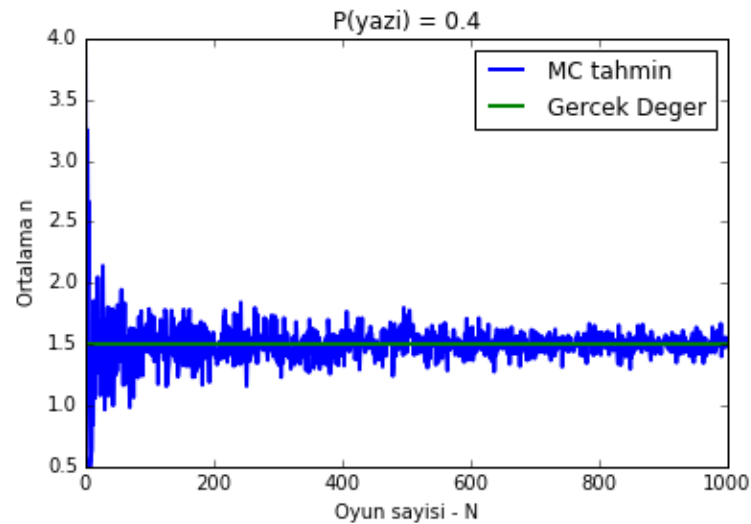
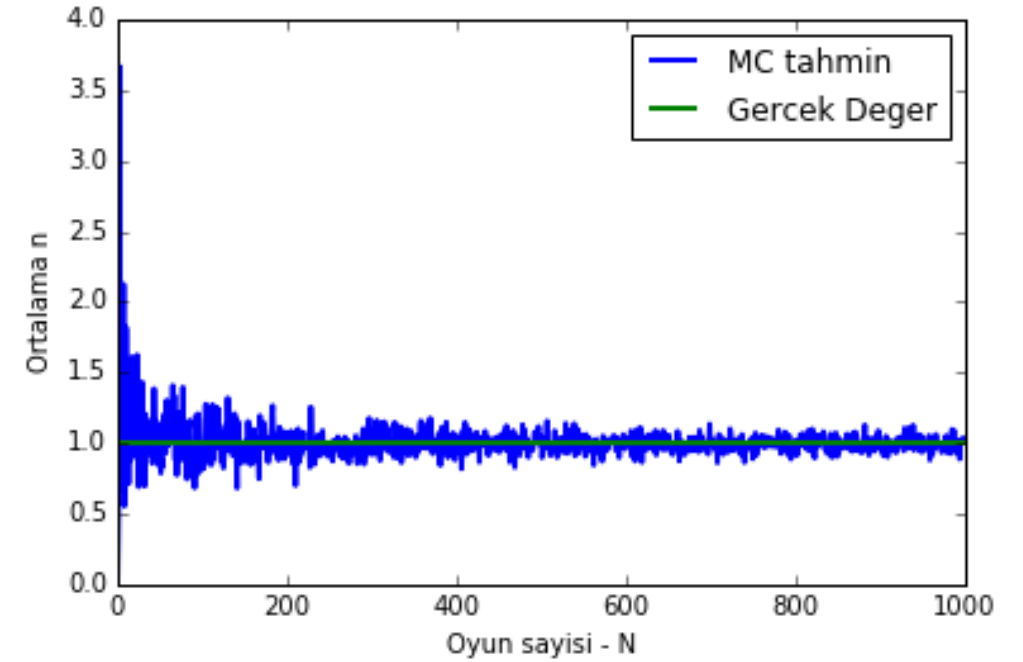
$$P(Y)= p \ ; \ P(T) = 1- p = q$$

```
N = 5
para = ['H', 'T']
prob = [0.5, 0.5]
denemeler = []
for i in range(N):
    paralar = []
    deneme = 0
    while(True):
        u = np.random.choice(para, p = prob)
        paralar.append(u)
        if(u == 'H'):
            print("Paralar: ", paralar)
            print('# Kacinci denemede yazi geldi: ', deneme+1)
            denemeler.append(deneme)
            break
        else:
            deneme += 1
```

```
('Paralar: ', ['T', 'H'])
('# Kacinci denemede yazi geldi: ', 2)
('Paralar: ', ['T', 'T', 'T', 'T', 'T', 'H'])
('# Kacinci denemede yazi geldi: ', 6)
('Paralar: ', ['H'])
('# Kacinci denemede yazi geldi: ', 1)
('Paralar: ', ['T', 'T', 'T', 'H'])
('# Kacinci denemede yazi geldi: ', 4)
('Paralar: ', ['H'])
('# Kacinci denemede yazi geldi: ', 1)
```

N = 1000 kez oynarsak ortalama kaç olur?

```
N = 1000
mean = []
para = ['H', 'T']
prob = [0.5, 0.5]
for i in range(N):
    denemeler = []
    for j in range(i+1):
        paralar = []
        deneme = 0
        while(True):
            u = np.random.choice(para, p = prob)
            paralar.append(u)
            if(u == 'H'):
                denemeler.append(deneme)
                break
            else:
                deneme += 1
        mean.append(np.mean(denemeler))
```



Oyuncak Model: Yazı gelene kadar at!



- Problem:

$P(n)$: Elimdeki parayı artarda attığımda üzerinde yazı yüzünün ilk defa $(n+1)$ denemede gelme olasılığı ($n= 0, 1, 2, 3, \dots$)

$$P(Y)=p ; P(T) = 1-p = q$$

$$P(n) = q^n p \text{ (Geometrik dağılım)}$$

- $P(n)$ bir olasılık dağılımı mı?

$$\sum_n P(n) = \sum_n q^n p = p \sum_n q^n = p \frac{1}{1-q} = 1$$

- Ortalama n değeri ve varyans:

- Generating Function:

$$f(z) = \sum_n P(n)z^n = \sum_n q^n p z^n = p \sum_n (qz)^n = \frac{p}{1-qz}$$

$$\bar{n} = \left. \frac{df}{dz} \right|_{z=1} = \sum_n n P(n) z^{n-1} \Big|_{z=1} = \sum_n n P(n) = \frac{pq}{(1-qz)^2} = \frac{q}{p}$$

$$\text{Varyans } \sigma^2 = \frac{q}{p^2}$$

Monte Carlo

- İki problemi çözmek için:
 - **Problem 1:** Verilen bir $P(x)$ olasılık dağılımından örnekler $\{x^{(r)}\}_{r=1}^R$ çekmek
 - **Problem 2:** Fonksiyonların bu dağılım altındaki beklenen değerlerini hesaplamak

$$\Phi = \langle \varphi(x) \rangle \equiv \int d^N x P(x) \varphi(x)$$

- $P(x)$: Hedef dağılım (target density)
 - x : N boyutlu vektör
- İlgilenebileceğimiz örnek $\varphi(x)$ fonksiyonları:

$$\varphi_1(x) = x, \quad \varphi_2(x) = x^2$$

$$\bar{x} = \Phi_1, \quad \overline{x^2} = \Phi_2; \quad \overline{(x - \bar{x})^2} = \Phi_2 - \Phi_1$$

- Eğer $P(x)$ 'den örnekler üretebilirsek, ikinci problemi çözebiliriz:

$$\hat{\Phi} = \frac{1}{R} \sum_r \varphi(x^{(r)})$$

Monte Carlo

- Neden $P(\mathbf{x})$ 'den örnekleme yapmak zor?
 - $P(\mathbf{x})$ fonksiyonunu belirli bir katsayıya kadar hesaplayabiliyoruz.

$$P(\mathbf{x}) = P^*(\mathbf{x})/Z$$

- Eğer $P^*(\mathbf{x})$ 'ı hesaplayabiliyorsak, neden bağımsız örnekler çekmek zor?
Genellikle Z fonksiyonunu (normalizasyon sabiti) bilmiyoruz.

$$Z = \int d^N \mathbf{x} P^*(\mathbf{x})$$

Z 'yi bilsek dahi yüksek boyutlarda her noktada P 'yi hesaplamadan örnek çekmek güç (nokta sayısı çok fazla)

- Monte Carlo yöntemleri **rastgele sayılar** ve çeşitli teknikler kullanarak belirli bir dağılımdan **bağımsız örnekler** üretmeyi ve sonrasında bu örnekleri kullanarak örneklerin fonksiyonlarının **beklenen değerlerini** hesaplamayı sağlıyor.

Eğer $P(\mathbf{x})$ 'den örnekler üretebilirsek, ikinci problemi çözebiliriz:

$$\hat{\Phi} = \frac{1}{R} \sum_r \varphi(\mathbf{x}^{(r)})$$

Monte Carlo yöntemleri neden çalışıyor?

- Yansız kestirici (unbiased estimator):

$$E_{\pi}\varphi(x) \approx \frac{\varphi(x^{(1)}) + \dots + \varphi(x^{(N)})}{N} \equiv \bar{E}_{\varphi,N}.$$

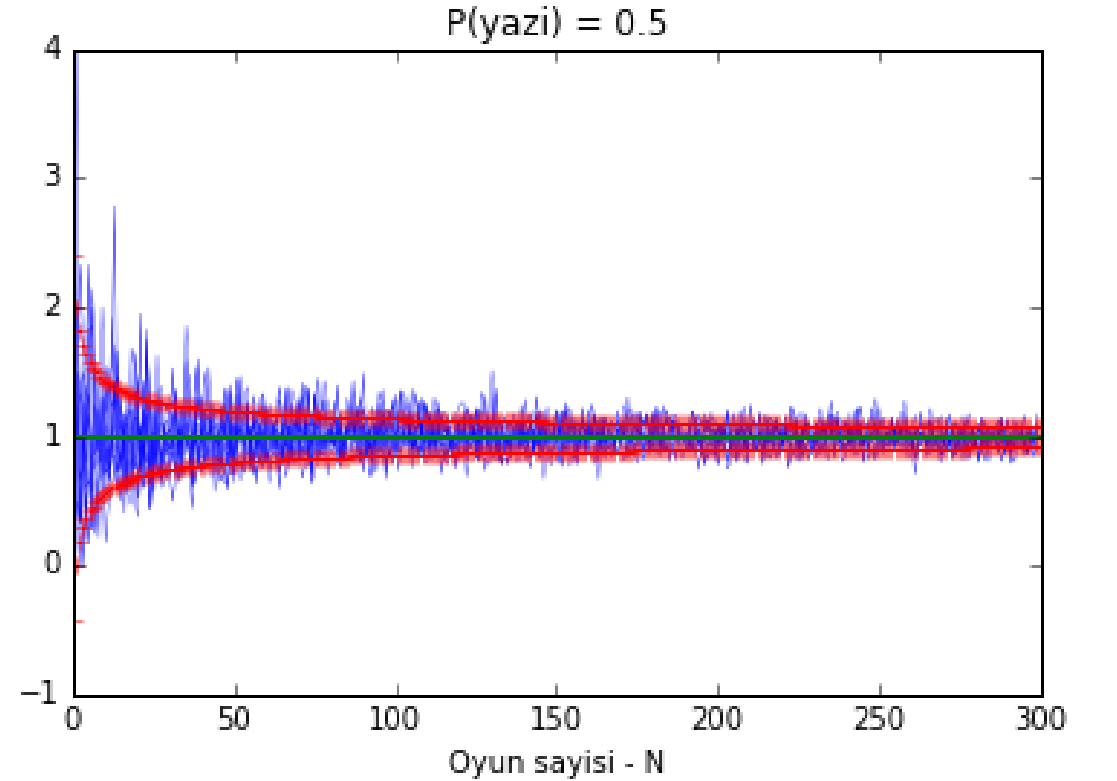
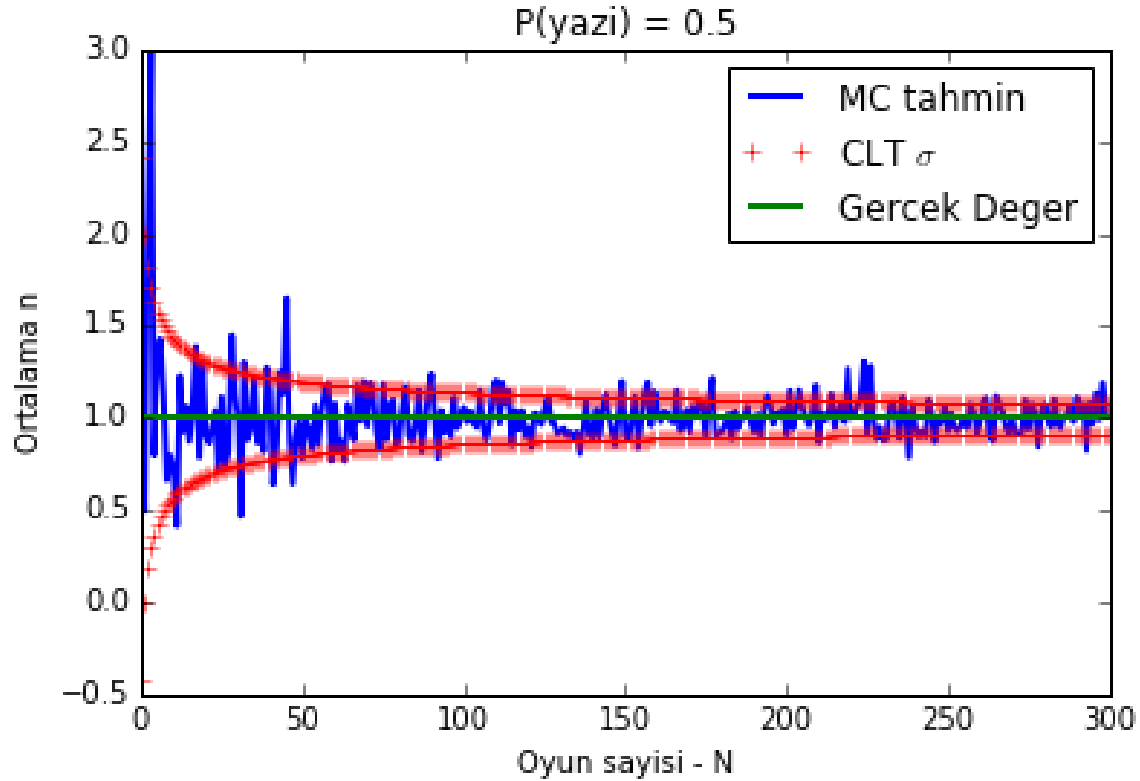
$$\bar{E}_{\varphi,N} \rightarrow \mu$$

- Sonlu örnek ile kestirim yaptığımızdan dalgalanmalar (fluctuations) kaçınılmaz!
- Merkezi Limit Teoremi (Central Limit Theorem – CLT): Büyük N’ler için ($N \rightarrow \infty$) dalgalanmalar normal dağılıma sahip

$$\bar{E}_{\varphi,N} \sim \mathcal{N}(\bar{E}_{\varphi,N} | \mu, \sigma^2/N)$$

- Eğer $\pi(x)$ gibi bir dağılım fonksiyonundan birbirinin aynısı ve bağımsız (iid) örnekler çekebilirsek Monte Carlo kestirimcisi ile:
 - Monte Carlo kestirimcisi dalgalanmalı da olsa gerçek değer yansız kestirimini veriyor. $\mu = E_{\pi}\varphi(x)$
 - Dalgalanmalar \sqrt{N} ile ölçekleniyor.
 - Yöntemin yakınsaması x ’in boyutundan tamamen bağımsız!

Yazı-Tura oyununa geri d6nelim



MC yöntemi: Reddetme Örnekleme

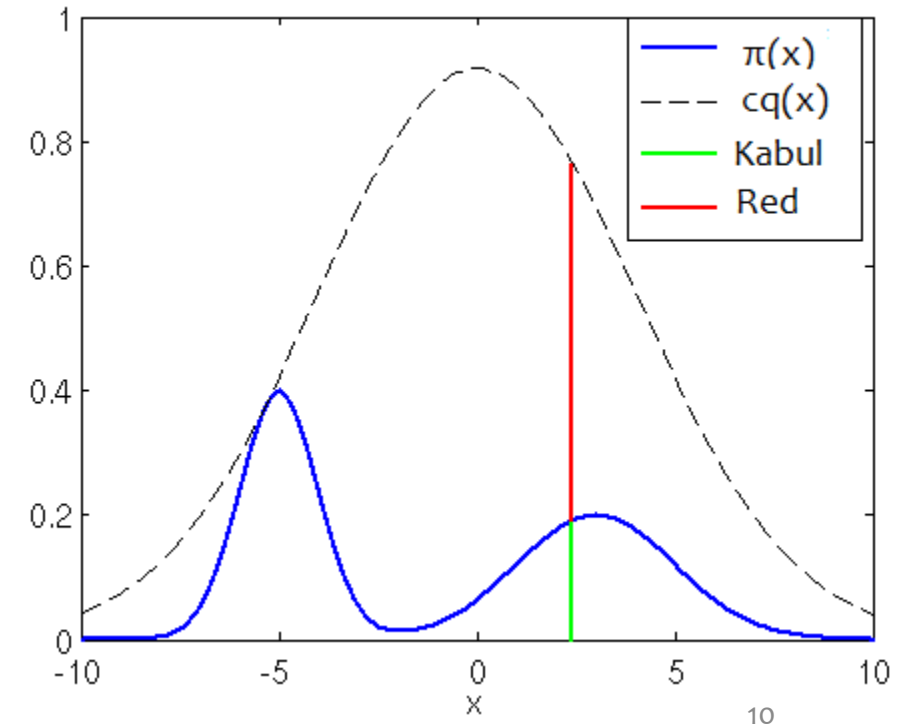
- Elimizde örneklememiz zor olan $\pi(x)$ ve örnekleyebildiğimiz bir $q(x)$ dağılım fonksiyonları olsun.
- **Temel fikir:** $q(x)$ 'den örnekler çekerek belirli bir reddetme/kabul etme kriteri uygulayarak kabul edilen örneklerin sonuçta $\pi(x)$ 'e göre dağılmış olmalarını sağlamak
- Gerekli şart: $q(x)$ 'in $\pi(x)$ 'i örtmesi (envelope) gerekiyor:

$$c q(x) > \pi(x) ; c > 1$$

- Örnekleri kabul şartı:

$$u \sim \text{Uniform}[0,1]$$


$$\frac{\pi(x)}{c q(x)} > u$$



MC yöntemi: Reddetme Örnekleme

- Farklı bir reddetme kriteri: Geometrik
 - Daire içinden düzgün dağılmış noktalar üretmek
 - $x, y \sim \text{Uniform}[0,1]$
 - Eğer $\sqrt{x^2 + y^2} < R \rightarrow$ Kabul Et; değilse Reddet
 - π 'yi hesaplama yöntemi!

$$\frac{n_{hit}}{n_{toplaml}} = \frac{\pi 1^2/4}{1^2} = \frac{\pi}{4}$$



MC yöntemi: Metropolis-Hastings

<<Metropolis-Hastings yöntemi Markov Zincirleri'nin durağan dağılımları kullanılarak örnekler üretmeye dayanıyor.>>

Peki Markov Zinciri nedir?

Markov Zinciri

- Belirli bir durum uzayında, ardışık olarak durumdan duruma rastgele geçişlerin olduğu süreçler
$$x^{(0)} \rightarrow x^{(1)} \rightarrow x^{(2)} \rightarrow \dots x^{(t)} \rightarrow \dots$$

- Markov Zincir'lerini tanımlayan 3 öge:

- Durum uzayı x ; zincirin alabileceği tüm değerleri içeren küme
- Geçiş operatörü (transition operatör) $p(x^{t+1}|x^t)$, x^t durumundan x^{t+1} durumuna geçiş olasılığını belirten fonksiyon
- ilk başta ($t = 0$) sistemin hangi durumlarda hangi olasılıkla olduğunu belirten başlangıç dağılımı $\pi(0)$

- Markov zinciri $\pi(0)$ 'daki dağılımdan bir durumdan başlayıp zamanla $p(x^{(t+1)}|x^{(t)})$ 'ya göre evrilir

- Belirli bir zamandaki dağılım yalnızca bir önceki durum dağılımına bağlıdır:

$$p(x^{(t)}|x^{(t-1)}, x^{(t-2)}, \dots, x^0) = p(x^{(t)}|x^{(t-1)})$$

- Belirli koşullar altında Markov zinciri $t \rightarrow \infty$ için **durağan (stationary) dağılıma** sahip!


$$p(x^{(t+1)}|x^{(t)}) = p(x^{(t)}|x^{(t-1)})$$

Markov Zinciri – Bir Örnek

- Üç farklı hava koşulu – {güneşli, sisli, yağmurlu}
- Eğer hava bugün güneşliyse:
 - $P(X^{haftaya} = \text{güneşli} | X^{bugün} = \text{güneşli}) = 0.8$
 - $P(X^{haftaya} = \text{sisli} | X^{bugün} = \text{güneşli}) = 0.15$
 - $P(X^{haftaya} = \text{yağmurlu} | X^{bugün} = \text{güneşli}) = 0.05$
- Eğer hava bugün yağmurluysa:
 - $P(X^{haftaya} = \text{güneşli} | X^{bugün} = \text{yağmurlu}) = 0.1$
 - $P(X^{haftaya} = \text{sisli} | X^{bugün} = \text{yağmurlu}) = 0.3$
 - $P(X^{haftaya} = \text{yağmurlu} | X^{bugün} = \text{yağmurlu}) = 0.6$
- Tüm bu olasılıklar 3x3 geçiş matrisi ile modellenebilir:

$$\begin{bmatrix} 0.8 & 0.15 & 0.05 \\ 0.4 & 0.5 & 0.1 \\ 0.1 & 0.3 & 0.6 \end{bmatrix}$$

- Eğer hava bugün sisliyse:
 - $P(X^{haftaya} = \text{güneşli} | X^{bugün} = \text{sisli}) = 0.4$
 - $P(X^{haftaya} = \text{sisli} | X^{bugün} = \text{sisli}) = 0.5$
 - $P(X^{haftaya} = \text{yağmurlu} | X^{bugün} = \text{sisli}) = 0.1$



Markov Zinciri – Bir Örnek

- Geçiş kuralı: $P = \begin{bmatrix} 0.8 & 0.15 & 0.05 \\ 0.4 & 0.5 & 0.1 \\ 0.1 & 0.3 & 0.6 \end{bmatrix}$

- Eğer Markov zincirini $x = [0 \ 0 \ 1]$ durumundan yani 1 olasılıkla yağmurlu durumdan başlatıp evriltirsek

$$\pi(0) = [0 \ 0 \ 1]$$


$$P(x^{1.hafta}) = \pi(0) * P = [0.1 \ 0.3 \ 0.6]$$

$$P(x^{2.hafta}) = P(x^{1.hafta}) * P = \pi(0) * P^2 = [0.26, 0.35, 0.39]$$

...

$$P(x^{24.hafta}) = \pi(0) * P^{24} = [0.59, 0.26, 0.15]$$

Durağan Dağılım



Markov Zinciri Monte Carlo (MCMC)

Temel Fikir: Durağan dağılımı örnek çekmek istediğimiz hedef dağılım olan öyle bir Markov Zinciri tasarlayalım ki, bu Markov Zinciri simule ederek durağan dağılıma ulaştıktan sonra çektiğimiz bir örnek, peşinde olduğumuz hedef dağılımdan olsun!

İşimizi görecektir Markov Zincirini (geçiş operatörünü) tasarlamamızın yöntemi: **Metropolis-Hastings algoritması**

Metropolis Örnekleyicisi

- **Başlangıç olarak** $x(0) \sim \pi(0)$ ile başlayıp bir önerme (proposal) fonksiyonu $q(x^t | x^{t-1})$ 'dan x^* örneği çekiyoruz. $q(x^t | x^{t-1})$ Markov zinciri geçiş operatörü gibi davranıyor.

- Üretilen x^* örneğinin kabul edilip edilmeyeceği kontrol ediliyor:


$$\alpha_{kabul} = \min\left(1, \frac{p(x^*)}{p(x^{t-1})}\right)$$

- Metropolis Örnekleyicisinin geçiş operatörü şu şekilde çalışıyor:

- $u \sim Uniform[0,1]$ eğer α_{kabul} 'den küçükse önerilen x^* 'i yeni durum olarak kabul et $\rightarrow x^t = x^*$
- Değilse bir önceki durumu koru $\rightarrow x^t = x^{t-1}$
- Tekrar et

- Örnek:

- $p(x) = \frac{1}{1+x^2}$
- $\pi(0) \sim N(0,1)$
- $q(x^t | x^{t-1}) \sim N(x^{t-1}, 1)$





Ising Modeli için Metropolis Örnekleyicisi


- Rastgele bir spin seç ve spin'in yönünü değiştirip değiştirmeyeceğine karar ver.
- Eğer yeni durum **düşük enerjiliyse** spin'i değiştir, aksi takdirde değiştirme
- Değiştirmeyi kabul etme olasılığı = $\min(1, \frac{p(x^*)}{p(x^{t-1})} = \exp(-\beta\Delta E))$

$$\Delta E = 2 * \sigma_i b_i \text{ (} b_i \text{ yerel alan)}$$

$$P(\text{kabul}; \Delta E, \beta) = \begin{cases} 1 & \Delta E < 0 \\ \exp(-\beta\Delta E) & \Delta E > 0 \end{cases}$$




$$b_i = +3 - 1 = 2$$




$$\Delta E = -2 * 2 = -4$$

Kabul etme!



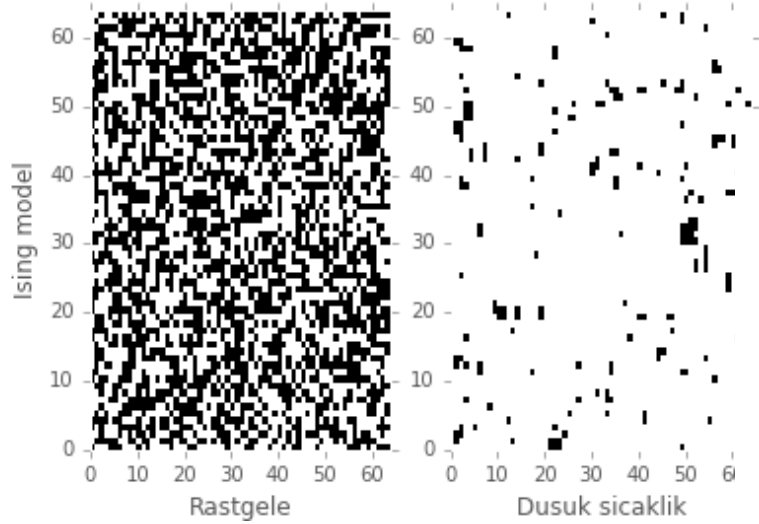


$$\Delta E = 2 * 2 = 4$$

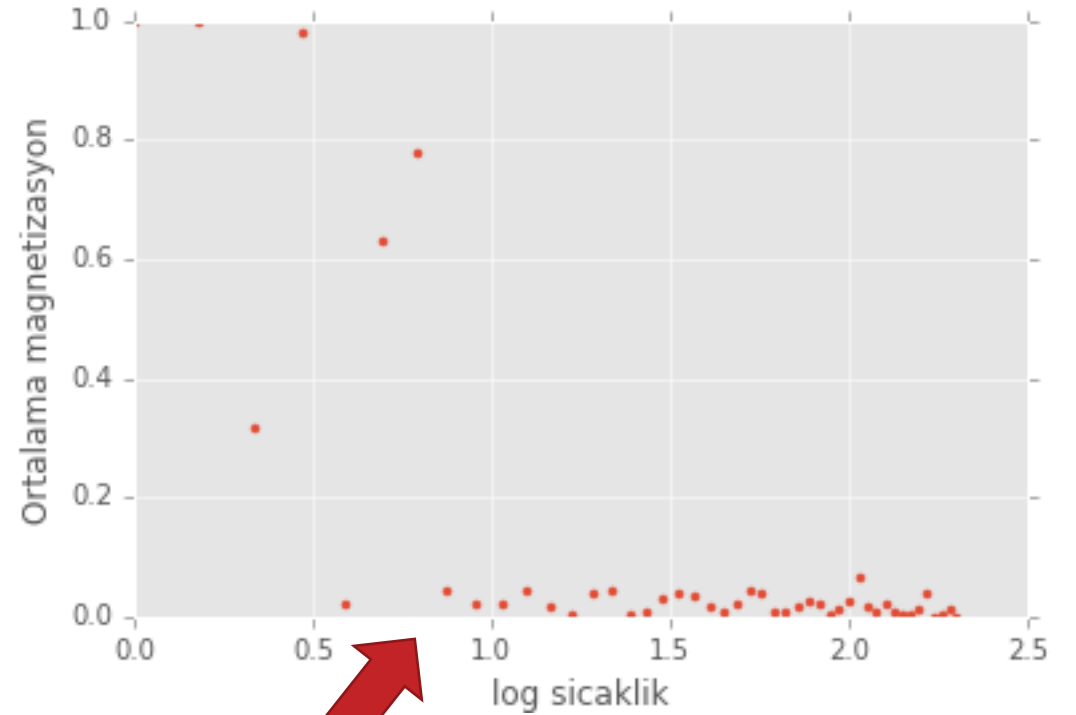
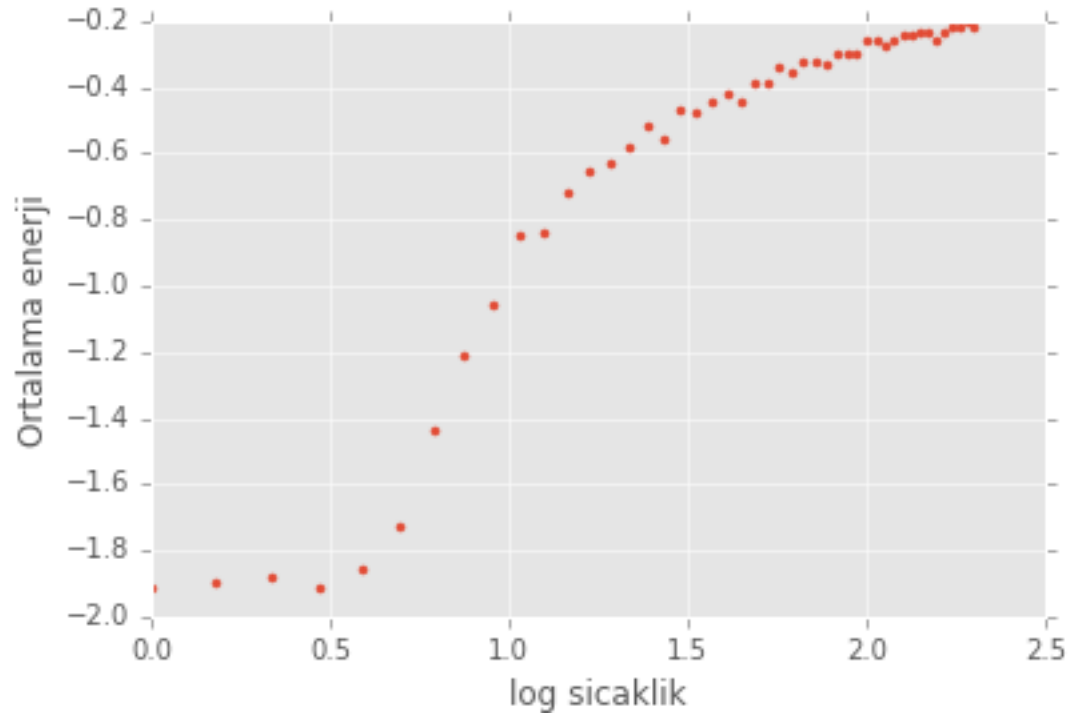
Kabul et



Ising Modelinden Örneklemeler






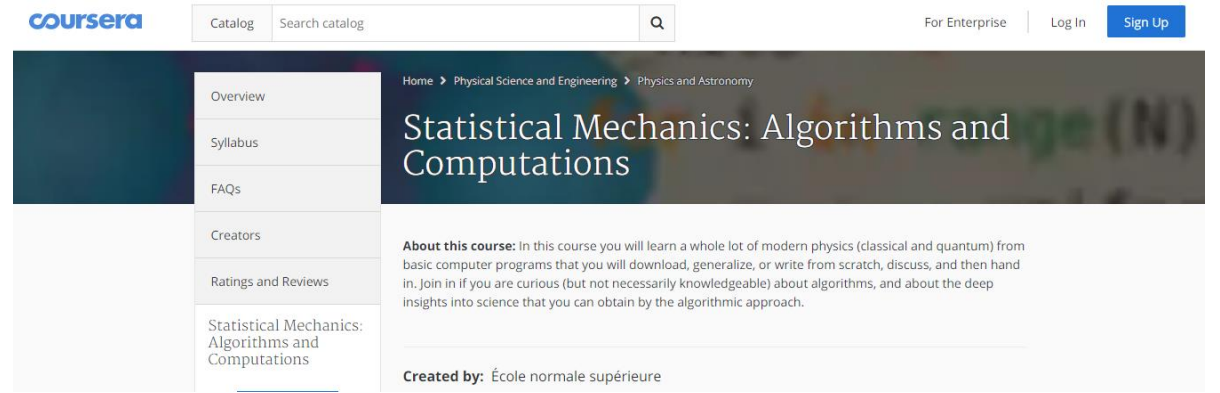
Ortalama Enerji / Magnetizasyon



Faz geiři $T \sim 2.2$

MC diyarından harikalar

- Önem örnekleme (importance sampling)
- Gibbs örnekleme
- Simulated Annealing
- Particle Filtering
- Hamilton Monte Carlo



Ders notlarına (yakında)
www.aslindafizik.blogspot.com ve
www.github.com/abayirli
adreslerinden ulaşabilirsiniz.

Teşekkürler!